Clasificación de Documentos



Daniel Rodríguez Aguilar

ÍNDICE

JUSTIFICACIÓN DEL PROYECTO	2
TIPO DE TEXTOS Y CATEGORÍAS	
TEXTOS DE ENTRENAMIENTO Y TEST	4
PALABRAS CLAVE	5
EXTRACCIÓN DE LAS CARACTERÍSTICAS DEL CONJUNTO DE ENTRENAMIENTO	6
IMPLEMENTACIÓN DE LOS CLASIFICADORES	7
REALIZACIÓN DE EXPERIMENTOS	8
MANUAL DE USUARIO	17
ANFXO	19

JUSTIFICACIÓN DEL PROYECTO

El objetivo es el de clasificar documentos que pertenecen a un mismo grupo pero que a su vez se dividen en subcategorías de éste. Para ello hemos hecho uso de dos algoritmos: Naive Bayes y kNN.

El algoritmo de Naive Bayes se fundamenta en el teorema de Bayes y su clasificador asume que la presencia o ausencia de una característica particular no está relacionada con la presencia o ausencia de cualquier otra característica, dada la categoría variable.

Por otro lado, el algoritmo kNN estima la probabilidad a posteriori de que un elemento pertenezca a una determinada categoría a partir de la información proporcionada por el conjunto de entrenamiento clasificándose en la clase más frecuente a la que pertenecen sus K vecinos más cercanos.

TIPO DE TEXTOS Y CATEGORÍAS

La aplicación que se ha llevado a cabo es la de clasificar noticias relacionadas con el deporte y se han considerado las siguientes categorías:

- Fútbol
- Baloncesto
- Tenis
- Fórmula 1
- Ciclismo

Se han elegido estas categorías ya que son fácilmente diferenciables, pero a su vez comparten términos que hacen que la clasificación no sea tan sencilla.

TEXTOS DE ENTRENAMIENTO Y TEST

Se han seleccionado textos que comparten las siguientes características:

Lenguaje: EspañolFormato: Texto plano

Para cada categoría se han recopilado la siguiente cantidad de documentos de entrenamiento:

Fútbol: 20
Baloncesto: 15
Tenis: 15
Fórmula 1: 15
Ciclismo: 15

Para cada categoría se han recopilado la siguiente cantidad de documentos adicionales para testear:

Fútbol: 2
Baloncesto: 2
Tenis: 2
Fórmula 1: 2
Ciclismo: 2

Todos los textos se han almacenado en su carpeta correspondiente ("entrenamiento" ó "adicionales") en formato ".txt". Para acceder a la fuente de cada texto se puede consultar el Anexo.

PALABRAS CLAVE

Se han elegido manualmente 20 palabras clave por categoría, en las cuáles se repite una o más palabras con otra categoría debido a su relevancia.

- **Fútbol:** ["futbol", "partido", "equipo", "resultado", "remate", "amarilla", "jugador", "minuto", "gol", "victoria", "derrota", "empate", "punto", "falta", "cabeza", "penalti", "portero", "defensa", "jornada", "balon"]
- Baloncesto: ["baloncesto", "alero", "doble-doble", "triple", "campo", "jugador", "asistencia", "partido", "rebote", "punto", "victoria", "derrota", "pivot", "cuarto", "personal", "segundo", "libre", "tiro", "base", "escolta"]
- Tenis: ["tenis", "partido", "masters", "slam", "ranking", "set", "tenista", "punto", "torneo", "victoria", "titulo", "atp", "juego", "manga", "dobles", "minuto", "mundo", "numero", "final", "saque"]
- **Fórmula 1:** ["mercedes", "mclaren", "ferrari", "bull", "renault", "victoria", "equipo", "escuderia", "carrera", "circuito", "f1", "vuelta", "piloto", "motor", "rueda", "temporada", "puesto", "pole", "curva", "coche"]
- Ciclismo: ["ciclista", "bici", "tour", "vuelta", "caida", "corredor", "etapa", "giro", "equipo", "meta", "kilometro", "esprint", "victoria", "circuito", "ruta", "recorrido", "italia", "españa", "francia", "puesto"]

EXTRACCIÓN DE LAS CARACTERÍSTICAS DEL CONJUNTO DE ENTRENAMIENTO

Para el procesado de textos se ha hecho uso del *kit de herramientas de lenguaje natural*, o más comúnmente conocido como NLTK. Este kit contiene un conjunto de bibliotecas y programas para procesamiento de lenguaje natural en Python.

Para ambos algoritmos se ha usado NLTK para obtener las raíces de las palabras que aparecen más de una vez para evitar sus plurales y diferentes formas en las que puede aparecer una determinada palabra con la misma raíz. Así como para eliminar del conjunto de palabras a analizar aquellas determinadas como "palabras vacías" o "stopwords", cuyo significado y relevancia en un texto es nulo.

Para el entrenamiento mediante kNN, los resultados obtenidos se almacenan en un documento de texto llamado "Entrenamiento kNN.txt", en el cuál se muestra:

- El orden de las palabras que han sido analizadas
- La frecuencia documental inversa de cada una de ellas
- La representación vectorial de cada uno de los textos de entrenamiento con los pesos de cada término en ellos

Para el entrenamiento mediante Naive Bayes, los resultados obtenidos se almacenan en un documento de texto llamado "Entrenamiento Naive Bayes.txt", en el cuál se muestra:

- El orden de las palabras que han sido analizadas
- Los valores P(c) y P(t|c) para cada una de las categorías existentes y términos del vocabulario

IMPLEMENTACIÓN DE LOS CLASIFICADORES

Clasificador kNN

La función que implementa este clasificador hace uso de los resultados del entrenamiento, obtenidos de "Entrenamiento kNN.txt", así como del nuevo documento a clasificar y un valor 'k'.

Al no ser clasificación binaria se ha implementado una variante del kNN que suma la similitud de los documentos de entrenamiento de la misma categoría más cercanos al nuevo, dado 'k'. El resultado devuelve la categoría cuyo valor de la suma es mayor.

Clasificador Naive Bayes

La función que implementa este clasificador hace uso de los resultados del entrenamiento, obtenidos de "Entrenamiento Naive Bayes.txt", así como del nuevo documento a clasificar.

El resultado devuelve la categoría cuya probabilidad de ser la correcta es mayor.

Nota: el resultado de las clasificaciones se muestra por consola y no se almacena en ningún archivo.

REALIZACIÓN DE EXPERIMENTOS

En este apartado se van a comparar los resultados de los distintos clasificadores. También se realizará una comparativa en cuanto a rendimiento para ambos procesos de entrenamiento y clasificación.

Entrenamiento

➤ **kNN**: 58.92737 segundos

```
| Project | Strip | St
```

➤ Naive Bayes: 0.647037 segundos

```
| Project | C + | Principle |
```

<u>Clasificador</u>

> knn

• "adicionalbaloncesto1"

```
## Workspace CuberDann/Dockt 27

| Workspace CuberDann/Dockt 27
| Workspace CuberDann/Dockt 27
| Workspace CuberDann/Dockt 27
| Workspace CuberDann/Dockt 27
| Determinents | State |
```

Clasificación: 'baloncesto'

Tiempo de ejecución: 0.68704 segundos

• "adicionalbaloncesto2"



Clasificación: 'baloncesto'

Tiempo de ejecución: 0.69204 segundos

"adicionalciclismo1"



Clasificación: 'ciclismo'

Tiempo de ejecución: 0.838047 segundos

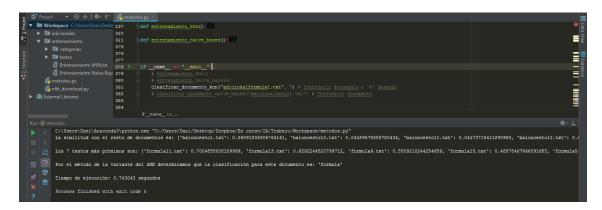
"adicionalciclismo2"



Clasificación: 'ciclismo'

Tiempo de ejecución: 0.968055 segundos

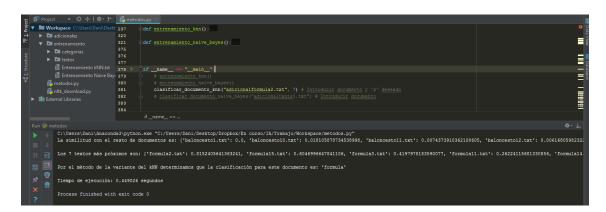
• "adicionalformula1"



Clasificación: 'formula'

Tiempo de ejecución: 0.743043 segundos

• "adicionalformula2"



Clasificación: 'formula'

Tiempo de ejecución: 0.449026 segundos

"adicionalfutbol1"



Clasificación: 'futbol'

Tiempo de ejecución: 0.70404 segundos

• "adicionalfutbol2"



Clasificación: 'futbol'

Tiempo de ejecución: 0.592034 segundos

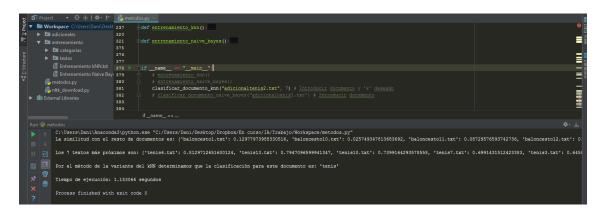
• "adicionaltenis1"



Clasificación: 'tenis'

Tiempo de ejecución: 0.35802 segundos

"adicionaltenis2"



Clasificación: 'tenis'

Tiempo de ejecución: 1.153066 segundos

Naive Bayes

• "adicionalbaloncesto1"

Clasificación: 'baloncesto'

Tiempo de ejecución: 0.016001 segundos

• "adicionalbaloncesto2"

Clasificación: 'baloncesto'

Tiempo de ejecución: 0.019001 segundos

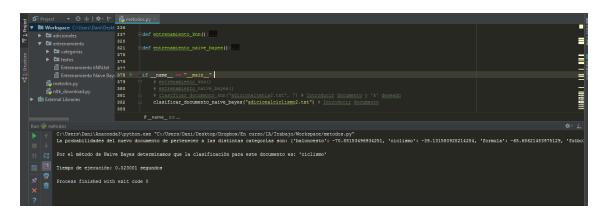
• "adicionalciclismo1"



Clasificación: 'ciclismo'

Tiempo de ejecución: 0.020001 segundos

"adicionalciclismo2"



Clasificación: 'ciclismo'

Tiempo de ejecución: 0.023001 segundos

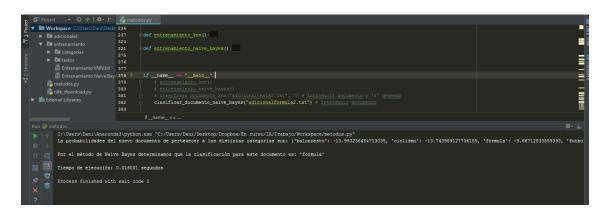
• "adicionalformula1"



Clasificación: 'formula'

Tiempo de ejecución: 0.019001 segundos

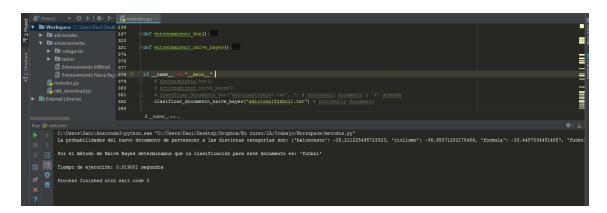
"adicionalformula2"



Clasificación: 'formula'

Tiempo de ejecución: 0.016001 segundos

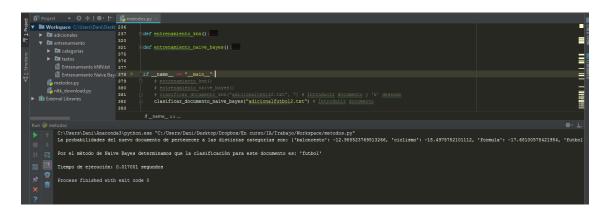
"adicionalfutbol1"



Clasificación: 'futbol'

Tiempo de ejecución: 0.019001 segundos

• "adicionalfutbol2"



Clasificación: 'futbol'

Tiempo de ejecución: 0.017001 segundos

• "adicionaltenis1"



Clasificación: 'tenis'

Tiempo de ejecución: 0.016001 segundos

"adicionaltenis2"



Clasificación: 'tenis'

Tiempo de ejecución: 0.025002 segundos

Conclusiones

- Ambos clasificadores han clasificado correctamente todos los textos adicionales.
- Tanto el proceso de entrenamiento como el de clasificación por Naive Bayes son destacablemente más eficientes que por kNN.

¿Qué necesito para poder ejecutar el programa correctamente?

- Python 3.6.0
- Kit de herramientas de lenguaje natural NLTK

Si no se tiene descargado NLTK, se adjunta un fichero "nltk_download.py" en el Workspace del proyecto. Para su descarga solo será necesario ejecutar este archivo con su IDE correspondiente.

Nota: si al ejecutar el fichero "nltk_download.py" hubiera algún error, será necesario instalar NLTK previamente siguiendo los pasos de esta fuente: "http://www.nltk.org/install.html"

¿Cómo añado una categoría y sus palabras clave?

- 1) Accedo a la ruta del proyecto ".../Workspace/entrenamiento/categorias"
- 2) Creo un archivo ".txt" cuyo título (sin acentos) será el nombre de la categoría que quiero añadir
- 3) Cada palabra clave que quiera añadir se escribirá en una línea distinta del documento

Nota: si el nombre de la categoría a añadir contiene un número, éste se debe omitir o determinar un nombre identificativo alternativo sin números para dicha categoría.

¿Cómo añado documentos al conjunto de entrenamiento?

- 1) Accedo a la ruta del proyecto ".../Workspace/entrenamiento/textos"
- 2) Creo un archivo ".txt" con el formato "{categoría}{idTextoCategoría}.txt". Ejemplo: para la categoría "futbol" los textos a añadir serán "futbol1.txt", "futbol2.txt", etc.
- 3) El interior del archivo debe contener el contenido del documento que queremos añadir como texto de entrenamiento.

¿Cómo añado documentos adicionales para probar los clasificadores?

- 1) Accedo a la ruta del proyecto ".../Workspace/adicionales"
- 2) Creo un archivo ".txt" con el formato "adicional{categoría}{idTextoAdicionalCategoría}.txt". Ejemplo: para la categoría "futbol" los textos adicionales a añadir serán "adicionalfutbol1.txt", "adicionalfutbol2.txt", etc.
- 3) El interior del archivo debe contener el contenido del documento que queremos añadir como texto adicional.

¿Cómo ejecuto los procesos de entrenamiento y clasificación?

- 1) Abro con el IDE correspondiente el archivo "metodos.py" que se encuentra en la ruta del proyecto ".../Workspace"
- Para ejecutar los procesos de entrenamiento nos iremos al final del documento y solo dejaremos descomentada la línea correspondiente al entrenamiento que queremos ejecutar. Ejemplo: entrenamiento_knn()

 Para ejecutar los procesos de clasificación nos iremos al final del documento y solo dejaremos descomentada la línea correspondiente al clasificador que queremos ejecutar. Ejemplo: clasificar_documento_knn("adicionaltenis2.txt", 7)

Nota: los resultados de la clasificación se mostrarán por consola.

> TEXTOS DE ENTRENAMIENTO

tenis1: http://www.marca.com/tenis/2017/11/26/5a1a9e10ca4741f75c8b458b.html

tenis2: http://www.marca.com/tenis/copa-

davis/2017/11/25/5a19975622601d12168b457c.html

tenis3: http://www.marca.com/tenis/2017/11/21/5a14711e22601d9e058b4649.html

tenis4:

http://www.marca.com/paralimpicos/2017/11/21/5a143d7322601da7058b4616.html

tenis5: http://www.marca.com/tenis/2017/11/20/5a12a350468aeb77118b45f2.html

tenis6: http://www.marca.com/tenis/copa-

masters/2017/11/19/5a11ed9be5fdea4e378b45c3.html

tenis7: http://www.marca.com/tenis/copa-

masters/2017/11/18/5a10b03fe2704e04288b463a.html

tenis8: http://www.marca.com/tenis/copa-

masters/2017/11/18/5a107f4de2704ec76e8b4636.html

tenis9: http://www.marca.com/tenis/copa-

masters/2017/11/18/5a105892e2704e12218b461c.html

tenis10: http://www.marca.com/tenis/copa-

masters/2017/11/17/5a0f5165ca4741cc118b4595.html

tenis11: http://www.marca.com/tenis/copa-

masters/2017/11/17/5a0eff11ca47414a588b467e.html

tenis12: http://www.marca.com/tenis/us-

open/2017/09/11/59b5ca3ce5fdea245f8b4647.html

tenis13: http://www.marca.com/tenis/us-

open/2017/09/09/59b38f6dca47418d6f8b4584.html

tenis14: http://www.marca.com/tenis/us-

open/2017/09/09/59b3256a268e3e15718b45cb.html

tenis15: http://www.marca.com/tenis/us-

open/2017/09/08/59b2d758e2704e7a3a8b45b8.html

formula1: http://www.marca.com/motor/formula1/gp-abudhabi/2017/11/27/5a1c1fc6268e3e75498b4694.html

formula2: http://www.marca.com/motor/formula1/gp-abu-dhabi/2017/11/27/5a1c1176268e3e737c8b466d.html

formula3: http://www.marca.com/motor/formula1/gp-abudhabi/2017/11/27/5a1c099a268e3ec7718b464c.html

formula4: http://www.marca.com/motor/formula1/gp-abu-dhabi/2017/11/27/5a1c0083268e3e89048b4616.html

formula5: http://www.marca.com/motor/formula1/gp-abudhabi/2017/11/26/5a1ab94922601dfd148b45f9.html

formula6: http://www.marca.com/motor/formula1/gp-abu-dhabi/2017/11/25/5a1997bee5fdea080e8b467c.html

formula7: http://www.marca.com/motor/formula1/gp-abu-dhabi/2017/11/25/5a196747468aeb12058b4607.html

formula8: http://www.marca.com/motor/formula1/gp-abudhabi/2017/11/25/5a196386e5fdea72308b4662.html

formula9: http://www.marca.com/motor/formula1/gp-abu-dhabi/2017/11/25/5a1944a5e2704e945d8b45c8.html

formula10: http://www.marca.com/motor/formula1/gp-abu-dhabi/2017/11/24/5a184650468aeb5f038b45ab.html

formula11: http://www.marca.com/motor/formula1/gp-abu-dhabi/2017/11/24/5a17fd0146163fd4488b4628.html

formula12: http://www.marca.com/motor/formula1/gp-abu-dhabi/2017/11/24/5a17db0546163f62548b460f.html

formula13: http://www.marca.com/motor/formula1/gp-abudhabi/2017/11/23/5a173208e2704e3e5a8b45ea.html

formula14:

http://www.marca.com/motor/formula1/2017/11/22/5a15aa3e268e3e133a8b45ac.ht ml

formula15:

http://www.marca.com/motor/formula1/2017/11/22/5a153380e5fdea73208b456d.ht ml

ciclismo1: http://www.marca.com/ciclismo/giro-italia/2017/11/26/5a1ae94c22601df20e8b4632.html

ciclismo2:

http://www.marca.com/ciclismo/2017/11/24/5a16fa6922601d6e498b4575.html

ciclismo3:

http://www.marca.com/ciclismo/2017/11/22/5a15e0e8e5fdea7f0a8b4620.html

ciclismo4:

http://www.marca.com/ciclismo/2017/11/20/5a0ed80aca4741d0588b46ac.html

ciclismo5:

http://www.marca.com/ciclismo/2017/11/27/5a1bfaf6268e3e9f3e8b45f6.html

ciclismo6:

http://www.marca.com/ciclismo/2017/11/27/5a1bf88a268e3e891b8b4604.html

ciclismo7:

http://www.marca.com/ciclismo/2017/11/18/5a10855122601d2e1f8b4655.html

ciclismo8:

http://www.marca.com/ciclismo/2017/11/17/5a0ece09ca474129438b466e.html

ciclismo9:

http://www.marca.com/ciclismo/2017/11/15/5a0c2c18268e3ed21f8b45a2.html

ciclismo10:

http://www.marca.com/ciclismo/2017/11/14/5a0ad2c9e2704eee518b4630.html

ciclismo11:

http://www.marca.com/ciclismo/2017/11/13/5a08bacf468aebe1248b45cb.html

ciclismo12:

http://www.marca.com/ciclismo/mundial/2017/09/24/59c3eddbca474109068b46c5.html

ciclismo13:

http://www.marca.com/ciclismo/mundial/2017/09/24/59c7c50d468aebdd108b461f.html

ciclismo14:

http://www.marca.com/ciclismo/mundial/2017/09/24/59c7f600468aebc2648b4671.html

ciclismo15:

http://www.marca.com/ciclismo/mundial/2017/09/23/59c657c5e5fdea3e6e8b4574.html

baloncesto1:

http://www.marca.com/baloncesto/nba/2017/11/26/5a1a705fca4741ac6c8b4578.ht

baloncesto2:

http://www.marca.com/baloncesto/nba/2017/11/26/5a1a78e7ca474114348b457e.ht ml

baloncesto3:

http://www.marca.com/baloncesto/nba/2017/11/26/5a1a7552ca47412f6a8b4574.ht ml

baloncesto4:

http://www.marca.com/baloncesto/nba/2017/11/26/5a1a7b6bca4741684d8b457b.ht ml

baloncesto5:

http://www.marca.com/baloncesto/nba/2017/11/26/5a1a8a1bca474125568b457f.ht ml

baloncesto6:

http://www.marca.com/baloncesto/nba/2017/11/26/5a1a85c1ca474193528b457a.ht ml

baloncesto7:

http://www.marca.com/baloncesto/nba/2017/11/25/5a19339a268e3e5c1d8b459c.ht ml

baloncesto8:

http://www.marca.com/baloncesto/nba/2017/11/25/5a192704268e3e641c8b4599.ht ml (1ra parte)

baloncesto9:

http://www.marca.com/baloncesto/nba/2017/11/25/5a192704268e3e641c8b4599.ht ml (2da parte)

baloncesto10:

http://www.marca.com/baloncesto/nba/2017/11/25/5a192704268e3e641c8b4599.ht ml (3ra parte)

baloncesto11:

http://www.marca.com/baloncesto/nba/2017/11/26/5a1a7f6dca474118658b4584.ht ml

baloncesto12:

http://www.marca.com/baloncesto/nba/2017/11/25/5a1918c1268e3ea0088b4596.html

baloncesto13:

http://www.marca.com/baloncesto/nba/2017/11/25/5a191160268e3e5a278b458a.ht ml

baloncesto14:

http://www.marca.com/baloncesto/nba/2017/11/25/5a190dbc268e3ecd768b459b.ht ml

baloncesto15:

http://www.marca.com/baloncesto/nba/2017/11/23/5a16bbaa468aebe8258b45fb.ht ml

futbol1: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada_10/ala_val/

futbol2: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada 12/pal lev/

futbol3:

http://www.marca.com/futbol/atletico/2017/11/26/5a19ee50e5fdeaeb648b4573.htm

futbol4: http://www.marca.com/claro-mx/futbol/mexicanos-mundo/2017/11/25/5a19c4b1ca4741bd4b8b463d.html

futbol5:

http://www.marca.com/futbol/girona/2017/11/25/5a19a8b1468aeb36028b4620.html

futbol6: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada 13/rma mga/

futbol7: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada_13/ala_eib/

futbol8: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada_13/cel_leg/

futbol9:

http://www.marca.com/futbol/celta/2017/11/25/5a18af67e5fdea221f8b4619.html

futbol10: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada_10/get_rso/

futbol11:

 $http://www.marca.com/eventos/marcador/futbol/2017_18/champions/1a_fase/jornada_5/grupo_e/sev_liv/\\$

futbol12: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada 12/sev cel/

futbol13: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada_12/ath_vil/

futbol14:

http://www.marca.com/eventos/marcador/futbol/2017_18/europa_league/1a_fase/jornada_5/grupo_a/asn_vil/

futbol15: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada_11/ala_esp/

futbol16: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada_12/mga_dep/

 $futbol 17: http://www.marca.com/eventos/marcador/futbol/2017_18/laliga/jornada_10/mga_cel/$

futbol18:

http://www.marca.com/eventos/marcador/futbol/2017_18/copa/dieciseisavos/ida/num_mga/

futbol19: http://www.marca.com/eventos/marcador/futbol/2017_18/la-liga/jornada_7/sev_mga/

futbol20:

 $http://www.marca.com/eventos/marcador/futbol/2017_18/europa_league/1a_fase/jornada_5/grupo_l/ros_rso/$

> <u>TEXTOS ADICIONALES</u>

adicionalfutbol1: http://www.marca.com/futbol/real-madrid/2017/11/19/5a11ea9622601d8f608b45ae.html

adicionalfutbol2:

http://www.marca.com/futbol/betis/2017/11/28/5a1d2f1b22601deb668b45eb.html

adicionaltenis1:

http://www.marca.com/tenis/2017/07/16/596b9f66e5fdea324e8b45e9.html

adicionaltenis2:

http://www.marca.com/tenis/wimbledon/2017/07/16/596b7d8ce2704ef9188b4663.html

adicionalformula1: http://www.marca.com/motor/formula1/gp-abudhabi/2017/11/28/5a1d2e2c268e3e4f688b45b6.html

adicionalformula2:

http://www.marca.com/motor/formula1/2017/11/27/5a1c3a2946163f412b8b45e9.html

adicionalciclismo1:

http://www.marca.com/ciclismo/2017/11/28/5a1cc1db22601dca6e8b461a.html

adicionalciclismo2:

http://www.marca.com/ciclismo/2017/11/28/5a1cc68022601ded658b4628.html

adicionalbaloncesto1:

http://www.marca.com/baloncesto/euroliga/2017/11/28/5a1c6fa3468aeb4c5f8b4653 .html

adicionalbaloncesto2:

http://www.marca.com/baloncesto/nba/2017/11/28/5a1d067422601df0658b4620.ht ml